



Liga acadêmica de ciência de dados da UFRJ.

Linhas por Roubos

PS Analytica 26.1

Uma análise das linhas de ônibus mais seguras
(e as mais perigosas) da cidade do Rio de Janeiro

Rebecca Gomes Simão

Diogo dos Santos Machado Vieira

Pedro Henrique Ferrari

Rio de Janeiro,

Maio de 2026

Sumário

Sumário.....	1
1. Descrição.....	3
2. Objetivos.....	5
2.1 Objetivo Geral.....	5
2.2 Objetivos Específicos.....	5
3. Dados Utilizados.....	7
Coleta de Dados:.....	7
Caracterização dos Dados:.....	7
Período:.....	7
Leitura:.....	8
delegacia.csv:.....	8
routes.csv:.....	8
trips.csv:.....	9
shapes_geom.csv:.....	9
4. Métodos.....	10
4.1 Metodologia.....	10
4.2 Técnicas e Algoritmos.....	10
Mapa:.....	10
Linhas:.....	11
Classificação de risco por intervalos:.....	12
4.3 Ferramentas e Tecnologias.....	14
5. Conclusão.....	16
Principais resultados.....	16
Insights obtidos.....	16
Limitações:.....	16
Melhorias futuras:.....	16
Implementação de um modelo de Machine Learning.....	17
Utilização do arquivo stops.csv e stop_times.txt.....	17
6. Referências.....	19

1. Descrição

Responsáveis pela seção:

- Diogo dos Santos Machado Vieira

Este relatório apresenta uma visão geral do projeto/estudo realizado, contextualizando o problema abordado, sua relevância e aplicação prática.

A segurança pública no Rio de Janeiro constitui um dos principais desafios enfrentados pela sociedade contemporânea, impactando diretamente a qualidade de vida da população e o desenvolvimento social e econômico da cidade. Marcado historicamente por desigualdades sociais, crescimento urbano desordenado e disputas territoriais ligadas ao crime organizado, o estado convive com elevados índices de violência que afetam tanto moradores quanto visitantes. Nesse contexto, discutir a segurança no Rio de Janeiro torna-se essencial para compreender as dificuldades enfrentadas pelo poder público na garantia da ordem, da proteção dos cidadãos e da promoção de políticas eficazes de combate à criminalidade.

Diante disso, torna-se necessária a criação de iniciativas capazes de contribuir para a redução da violência e para o fortalecimento da sensação de segurança da população. A persistência desses problemas têm como consequências, entre outras, a insegurança em espaços públicos e a dificuldade do acesso à cidade. No livro "O Direito à Cidade" de Henri Lefebvre, ele define esse conceito, principalmente, como o direito de todos os cidadãos de habitar e utilizar a cidade, isso inclui a possibilidade de transporte dentro da cidade e o acesso aos seus espaços.

Este trabalho, portanto, é uma proposta de auxílio à solução desse problema do âmbito da segurança no Rio de Janeiro, tendo como foco a segurança nos transportes públicos, mais especificamente nos trajetos e linhas de ônibus. A ideia principal é que seja um sistema voltado para profissionais da segurança pública, de forma a exibir informações úteis que auxiliem na sua decisão estratégica.

Como o escopo do projeto está contido na relação entre ocorrências em transporte público por área de divisão de segurança (nesse caso as CISP), a limitação do projeto reside na ideia que as ocorrências são sempre registradas no local onde aconteceram e isso não é sempre verdade, e no índice de segurança ser unicamente baseado nesses moldes, sem levar previamente em conta outras características do espaço físico e/ou social do Rio de Janeiro.




Figura 1 - Inserir depois de validarem a imagem do mapa de calor com a linha exemplo.

2. Objetivos

Responsáveis pela seção:

- Diogo dos Santos Machado Vieira

2.1 Objetivo Geral

O objetivo do projeto é desenvolver um sistema que disponibilize as informações críticas de segurança. Essas informações baseadas nos moldes do escopo do mesmo, serão exibidas no sistema de forma visual e de simples entendimento para facilitar as decisões dos profissionais de segurança pública.

2.2 Objetivos Específicos

Dentre as principais funcionalidades que se espera do sistema estão:

1. Mapa de calor (Figura 2) da cidade do Rio de Janeiro e entornos, para uma visualização rápida de áreas de maior necessidade de intervenção.

Mapa com as CISPS do Rio de Janeiro




Figura 2 - Mapa de calor de CISPs x Ocorrências

2. A possibilidade de selecionar/pesquisar linhas e trajetos de ônibus, para que as mesmas sejam exibidas no mapa com suas devidas estatísticas de segurança baseadas na relação entre os espaços percorridos e as ocorrências registradas em cada um deles (Figura 3).




Figura 3 - Linhas x Ocorrências

3. Panorama temporal dos dados projetado no mapa, para visualização da influência dos períodos e anos no índice de segurança da cidade baseado na quantidade de ocorrências por ano (Figura 4).




Figura 4 - Tempo x Ocorrências

4. Comparativo entre informações (Risco, trajeto, quantidade de ocorrências) de diferentes linhas e sua exibição (Figura 5).




Figura 5 - Análise comparativa de linhas

3. Dados Utilizados

Responsáveis pela seção:

- Rebecca Gomes Simão

Coleta de Dados:

A base de dados foi construída por dados de transporte do **SMTR (Sistema Municipal de Transportes)** com o **ISP (Instituto de Segurança Pública do RJ)**, fontes abertas e confiáveis mantidas pelo Governo e Estado do Rio de Janeiro, e atualizadas recorrentemente, gerando uma segurança para nossa análise de dados e futura geração de conclusões vindas deles. O objetivo era **cruzar as linhas de ônibus com as regiões da cidade do Rio de Janeiro**, divididas em CISP's pelo Instituto de Segurança Pública do RJ, as quais tinham os dados da quantidade de roubos em ônibus naquela área que a CISP cobria. Dessa forma, tornava possível cruzar essas informações e obter o nível de **Exposição a Roubo que um cidadão carioca lidaria ao acessar uma determinada linha**.

Para tal, colhemos os seguintes Datasets:

- **Sistema Municipal de Transportes**
 - routes.csv;
 - trips.csv;
- **Instituto de Segurança Pública do RJ**
 - delegacias.csv;
 - shape_id.csv;
 - shape_geom.csv;
 - path_shape;

As etapas iniciais, como limpeza, exploração e *Feature Engineering* foram desenvolvidas no Google Colab, pela facilidade de testagem e velocidade, e posteriormente passadas para o **Python**, para criação do protótipo no **Streamlit**.

Caracterização dos Dados:

Período:

Para a escolha do período da análise, observamos a média de roubos nos períodos pré-pandemia, durante e pós, encontrando valores bem destoantes:

-> Média pré-pandemia: 15507 | Média pandemia: 8648 | Média pós-pandemia: 5139

Assim, optamos por nos mantermos nos dados mais atualizados, sendo de 2022 até a data presente, para que não tenhamos essas interferências.

Leitura:

Foi utilizado o parâmetro **usecols** na leitura dos arquivos CSV, permitindo carregar apenas as colunas necessárias para a análise. Essa estratégia reduziu significativamente o consumo de memória e melhorou o desempenho do processamento.

Além disso, para o mesmo objetivo, foi realizada a **retirada das duplicatas antes do cruzamento** das planilhas (com a função *merge*), evitando cruzamento de linhas desnecessárias.

delegacia.csv:

Tipos de dados	Int64
Volume	1.4 MB
Nulos	0
Duplicados	0

Colunas de interesse:

- Quantidade de roubos;
- Ano e mês da ocorrência;
- Número da CISP (territórios de atuação das delegacias de bairro, como a CISP 9, que corresponde a região do flamengo);
- Número da RISP (grandes regiões que agrupam várias CISPs).

routes.csv:

Tipos de dados	Object
Volume	872.9+ KB
Nulos	0
Duplicados	35915
Rotas únicas	1325

O número de duplicatas elevado é esperado, uma vez que na base original há diversas variações que fazem com que as rotas únicas 1325 sejam expandidas a mais variações não úteis dentro do nosso escopo. A mesma quantidade, aliás, foi notada nas tabelas analisadas posteriormente.

Colunas de interesse:

- route_id: usado para cruzar com a planilha trips.csv;
- route_short_name: número do ônibus;
- route_long_name: descrição do projeto, renomeado "descrição";

trips.csv:

Tipos de dados	Object e Float64
Volume	21.2+ MB
Nulos trip_headsign	452
Nulos direction_id	9
Nulos shape_id	1
Duplicados	35915
Rotas únicas	1325

Os valores nulos de trip_headsign (nome da linha) foram preenchidos com "Sem letreiro", enquanto os de shape_id e direction_id foram apagados.

Colunas de interesse:

- route_id: para cruzar com a routes.csv;
- trip_headsign: nome da linha
- direction_id: para definir se ida ou volta, sendo 0, ida, e 1, volta;
- shape_id: para conseguir a rota das linhas;
- trip_id: seria utilizado para cruzar com stop_times (entrega sequência de pontos de parada do ônibus).

shapes_geom.csv:

Tipos de dados	object
Volume	218.0+ KB
Nulos	0
Duplicados	35915
Rotas únicas	1325

Colunas de interesse:

- shape_id: Para cruzar com os dados de trips e routes;

- shape: informações das coordenadas das linhas, conseguindo ser traduzidas para informações de GPS para plotagem das linhas

4. Métodos

Responsáveis pela seção:

- Rebecca Gomes Simão
- Pedro Henrique Ferrari Nascimento

4.1 Metodologia

Após a coleta e limpeza dos dados, os trajetos únicos foram isolados para se tornarem linhas de rotas plotáveis em gráfico, com informações agregadas de cada coletivo. Além disso, utilizando os dados de shape oriundos da ISP, foi possível plotar o mapa do Rio de Janeiro dividido por regiões. Dessa forma, o próximo passo foi o cálculo de exposição a risco de roubo.

4.2 Técnicas e Algoritmos


- Modelos utilizados:
 - **Agregação por CISP:** Filtramos os dados por ano, mês e RISP, e depois somamos os roubos por CISP. Assim, conseguimos saber quantos roubos ocorreram em cada CISP e, conseqüentemente, alimentar o mapa do calor que foi implementado na interface.
 - **Cruzamento entre linhas e CISPs:** usando o `gpd.sjoin`, foi feita uma junção espacial entre os trajetos de linhas de ônibus e áreas de CISPs. Os trajetos de linhas de ônibus são representados como `LineString`, enquanto as CISPs são representadas como polígonos. Sendo assim, combinando esse cruzamento com dados de roubo por CISP, conseguimos construir uma visualização geográfica ao longo dos trajetos.
 - **Modelo de exposição ao risco por CISP:** após descobrir por quais CISPs cada linha passa, conseguimos obter uma métrica chamada "exposicao_roubo_total", que é calculada pela soma dos roubos registrados nas CISPs atravessadas pela linha.
 - **Comparativo entre duas linhas de ônibus:** criamos uma aba para comparar duas linhas de ônibus, com possibilidade de escolher entre ida, volta ou ambos os sentidos, e comparar o risco associado a cada linha.

Mapa:

A Divisão Territorial de Segurança Pública, também fornecida pelo ISP, possui arquivo de Bases cartográficas com as coordenadas necessárias (polígonos) para se

desenhar as áreas cobertas de cada delegacia, que, cruzadas com tabela de crimes ordenados, resultam na cidade do Rio de Janeiro. Assim, no Colab, utilizando as bibliotecas de **geopandas** para conseguir converter os polígonos em coordenadas entendíveis, **matplotlib**, para plotar o gráfico com as separações de cada região e **mapclassify**, para produzir um mapa de calor que fica mais vermelho conforme maior exposição ao risco, o resultado é o mapa abaixo:


Mapa com as CISPS do Rio de Janeiro



Linhas:


As linhas de ônibus foram desenhadas utilizando a planilha `shapes_geom.csv`. Inicialmente são filtrados os `shapes_id` apenas das linhas de ônibus que serão analisadas (`locomocao_sem_duplicata`) e são cruzados dos datasets com as informações de cada linha e da localização geográfica em que elas passam. Feito isso, converte-se a informação presente na coluna `'geometry'` (um `linestring` com coordenadas em formato de texto) e são transformadas em uma linha geométrica matemática, possível de ser compreendida como coordenadas geográficas, utilizando o padrão `"EPSG:4326"`, de GPS.

<Axes: >

**Relação:**

As linhas e o mapa são cruzados usando interseção (se a linha de ônibus passar por 10 delegacias, a tabela terá 10 colunas, uma com cada delegacia e a respectiva quantidade de roubos que ocorreram na região). Feito isso, agrupamos os roubos de cada delegacia tornando um valor único, para gerar a exposição ao roubo da linha em específico.


...

Mapa com linhas de ônibus e áreas de risco de roubos


Classificação de risco por intervalos:

Inicialmente pensamos em utilizar classificação feita pelo `pd.qcut`, dividindo por nota a cada 10% (ou seja, primeiros 10%, nota 1, após, nota 2 e assim por diante). A técnica, no entanto, não se mostrou eficaz, classificando rotas seguras com risco alto por ter mais rotas com pouco roubo.

Trajetó 325 (Azul: Ida / Verde: Volta)



Para validar o problema, foi plotado o gráfico do ônibus 325, que aparecia com nota 10, embora seu trajeto passasse por pelo menos 2 CISPs de risco baixo - como notado no mapa de calor. Analisando o histograma, é possível perceber que a maior parte dos ônibus têm notas baixas. Assim, a divisão dos `.qcut()` inerentemente resultaria em uma má classificação, pois avalia densidade.



Pensamos então em analisar intervalos, dividindo a nota em 5 partes iguais que variam conforme quantidade de roubos por linha. A tabela acima tem a relação de quantidade de ônibus por nota recebida.

- Hiperparâmetros principais: Como não usamos nenhum modelo de Machine Learning, o que temos são parâmetros básicos.

4.3 Ferramentas e Tecnologias

- Linguagens:
 - **Python** foi a linguagem principal utilizada para todo o desenvolvimento, desde o processamento de dados até a criação da interface com **Streamlit** utilizando versionamento com **Git** e com auxílio do **Live Share**.
- Bibliotecas:
 - **Pandas**: Manipulação de dados tabulares, leituras de arquivos CSV e Parquet, além de agregações.
 - **GeoPandas**: Utilizada para análise geoespacial, permitindo a leitura de shapefiles e operação de spatial joins entre linhas(trajetos) e polígonos(CISPs).
 - **Streamlit**: Biblioteca utilizada para construir a interface web interativa.
 - **Folium & Streamlit-Folium**: Renderização dos mapas interativos, criação da camada calor e exibir os trajetos de ônibus no navegador. Substituímos o **Matplotlib** pelo Folium, no protótipo final, devido a sua interatividade com o usuário.
 - **Shapely(função WKT)**: Conversão de strings de geometria do arquivo shapes para objetos geográficos que o Python consegue processar.
- Infraestrutura:
 - **Streamlit Framework**: Foi usado para criar a interface web interativa, com exibição de mapas, filtros para o usuário, etc.
 - **Armazenamento Local**: Os dados são consumidos a partir de arquivos CSV e Parquet(formato utilizado para reduzir o tamanho de alguns arquivos e acelerar as operações), de forma local.

5. Conclusão

Responsáveis pela seção:

- Pedro Henrique Ferrari
- Rebecca Gomes Simão

Principais resultados

O projeto resultou na criação de uma interface de geoprocessamento que integra dados de segurança pública do ISP com dados de mobilidade urbana do SMT. Assim, conseguimos mapear a concentração de roubos em coletivo por CISP, atribuir uma nota de risco a cada linha específica e comparar duas rotas de ônibus para obter insights.

Insights obtidos:

- Foi observado uma drástica redução no número de roubos a coletivos no período pós pandemia(após 2020).
- Algumas CISPs são extremamente seguras, enquanto outras são têm números altíssimos de roubos registrados. Isso mostra uma grande disparidade entre regiões.
- O pd.qcut não se mostrou eficaz, classificando rotas seguras com risco alto por ter mais rotas com pouco roubo. Preferimos manter o grupo equilibrado.

Limitações:

- A principal limitação da nossa análise encontra-se no fato de que o modelo pressupõe que os crimes são registrados na exata CISP onde ocorreram. Isso não é 100% verdade, pois caso um roubo aconteça em um transporte público, a vítima pode registrar o roubo apenas na delegacia do seu destino.
- A agregação em nível de CISP generaliza o risco para toda a região, ou seja, não é possível saber em qual rua ou bairro o crime ocorreu. Isso acontece pois cada CISP contém diversas delegacias.
- As paradas de cada linha de ônibus deveriam ser analisadas e utilizadas no cálculo do risco. Uma linha que passa por uma CISP com 7 paradas é relativamente mais perigosa do que uma linha que passa por 3 paradas, uma vez que a parada é uma peça chave para que o roubo aconteça. Sendo assim, seria interessante incluir o número de paradas no cálculo do risco por linha.
- Nosso projeto também considera o dataset disponibilizado no site do Instituto de Segurança Pública do Rio de Janeiro, mas não conseguimos uma API para obter dados em tempo real. Infelizmente, por exemplo, só temos acesso a dados até Março de 2026. Tentamos entrar em contato com um comissário da polícia civil pelo Instagram, visto que ela posta diversos vídeos falando sobre análises de segurança pública com informações mais detalhadas, como dia da semana, rua e horário, mas não obtivemos resposta. Seria muito interessante ter acesso a essas informações.


Melhorias futuras:

- Maior detalhamento dos roubos, caso tivéssemos acesso a dados um pouco mais minuciosos, como faixa de horário do crime e dia da semana.
- Utilizar dados do arquivo stops.parquet para identificar os pontos de parada de uma linha de ônibus, a fim de determinar um risco mais preciso.
- Implementação de um modelo de Machine Learning para prever algum target, por exemplo, baseado nas informações que temos.

Utilização do arquivo stops.csv e stop_times.txt

A utilização das informações de pontos de ônibus, ao invés de exclusivamente linha, é relevante para análise futura. A ideia foi iniciada no colab, porém não implementada no protótipo final.

Trajetos e Paradas - grande e bom 325



Foi pensado na implementação das seguintes funcionalidades:

1. **Aumento de nota de risco em linhas que tem mais paradas em regiões perigosas**
- uma linha que tem uma parada em uma cisp com muito roubo está menos exposta a sofrer com esse problema do que uma linha que possui 3 paradas, então cruzar essa informações agregaria na melhoria da classificação;
2. **Classificação de risco por trajeto personalizável** - um cidadão que pega o 325 - exemplo acima para melhor visualização - do fundão até a ilha do governador é menos exposto ao risco do que um que pega no centro. Assim, essa separação permitiria também uma melhoria significativa na classificação;

3. **Integração de linhas** - Tendo o ponto de partida e chegada desejado do usuário, é possível escalar o projeto mostrando o nível de risco associado de diferentes combinações de ônibus.

6. Referências

Listar todas as fontes utilizadas (artigos, datasets, bibliotecas, etc.).

Secretaria Municipal de Transportes – SMTR – A Secretaria Municipal de Habitação atua na urbanização e regularização de favelas e loteamentos, ao mesmo tempo em que promove a construção de moradias em áreas dotadas de infraestrutura, buscando atender principalmente a população de baixa renda. Disponível em: <<https://transportes.prefeitura.rio/>>.

Dados Abertos - Instituto de Segurança Pública. Disponível em: <<https://www.ispdados.rj.gov.br/>>.

PANDAS. pandas documentation — pandas 1.0.1 documentation. Disponível em: <<https://pandas.pydata.org/docs/>>.

GeoPandas 0.7.0 — GeoPandas 0.7.0 documentation. Disponível em: <<https://geopandas.org/>>.

STREAMLIT. Streamlit • The fastest way to build and share data apps. Disponível em: <<https://streamlit.io/>>.

Folium — Folium 0.11.0 documentation. Disponível em: <<https://python-visualization.github.io/folium/>>.

RANDYZWITCH. GitHub - randyzwitch/streamlit-folium: Streamlit Component for rendering Folium maps. Disponível em: <<https://github.com/randyzwitch/streamlit-folium>>.

Shapely — Shapely 2.1.1 documentation. Disponível em: <<https://shapely.readthedocs.io/>>.